

Dicionário de Componentes do Pipeline

O sistema segue um fluxo estruturado de processamento de dados:

- Coleta de dados a partir de fontes internas e externas
- Tratamento e limpeza das informações
- Seleção das variáveis mais relevantes (features)
- Treinamento de um modelo de Machine Learning
- Avaliação e validação do modelo
- Implementação de um motor de predição
- Geração de um score de risco para cada cliente

O resultado é um indicador numérico ou categórico que representa o risco de inadimplência.

Etapa de treinamento:

Fonte de Dados (CSV / SQL / API Externa)

- **Descrição:**
Fornecer os dados brutos utilizados no sistema. Esses dados podem vir de arquivos CSV, bancos de dados relacionais (SQL) ou APIs externas.
- **Saída:**
Dados brutos para a etapa de tratamento.
- **Tecnologias sugeridas:**
PostgreSQL, APIs REST, Cloud, CSV.

Tratamento e Limpeza

- **Descrição:**
Etapa responsável por corrigir inconsistências, remover dados inválidos e padronizar os dados.

- **Entrada:**
Dados brutos.
- **Processamento:**
 - Tratamento de valores nulos
 - Correção de formatos
 - Padronização de dados
- **Saída:**
Dados limpos e estruturados.
- **Tecnologias sugeridas:**
Python, Pentaho, SQL.

Identificação e Escolha de Features

- **Descrição:**
Seleção das variáveis mais relevantes para o modelo de Machine Learning.
- **Entrada:**
Dados tratados.
- **Processamento:**
 - Análise de correlação
 - Seleção de variáveis importantes
 - Remoção de variáveis irrelevantes
- **Saída:**
Dataset otimizado para treinamento.
- **Tecnologias sugeridas:**
Python, análise estatística.

Algoritmo de Machine Learning

- **Descrição:**
Modelo responsável por aprender padrões dos dados e prever o comportamento do cliente.
- **Entrada:**
Dados com features selecionadas.

- **Processamento:**
Treinamento do modelo com base em dados históricos.
- **Saída:**
Modelo treinado.
- **Tecnologias sugeridas:**
Random-Forest, XGBoost, TensorFlow.

Análise de Resultados

- **Descrição:**
Avaliação da performance do modelo.
- **Entrada:**
Modelo treinado + dados de teste.
- **Processamento:**
Cálculo de métricas como:
 - Acurácia
 - Precisão
 - Recall
 - F1-score
- **Saída:**
Relatório de desempenho.
- **Tecnologias sugeridas:**
Python (Scikit-learn), Matplotlib.

Validação do Modelo

- **Descrição:**
Confirma se o modelo é confiável para uso em produção.
- **Entrada:**
Resultados da análise.
- **Processamento:**
 - Validação cruzada
 - Testes com dados novos

- **Saída:**
Modelo aprovado ou rejeitado.
- **Tecnologias sugeridas:**
Scikit-learn, TensorBoard.

Etapa dos Dados Cadastrais

Validação e Consistência dos Dados

- **Descrição:**
Garante que os dados de entrada no sistema estejam corretos antes da predição.
- **Entrada:**
Dados fornecidos pelo usuário.
- **Processamento:**
 - Verificação de formato
 - Validação de campos obrigatórios
- **Saída:**
Dados válidos para processamento.
- **Tecnologias sugeridas:**
Python, APIs.

Pré-processamento

- **Descrição:**
Transforma os dados no formato esperado pelo modelo.
- **Entrada:**
Dados validados.
- **Processamento:**
 - Normalização
 - Codificação de variáveis
- **Saída:**
Dados prontos para o modelo.

- **Tecnologias sugeridas:**
Scikit-learn, Pandas, Feature-engine.

Motor de Predição

- **Descrição:**
Executa o modelo treinado para gerar previsões.
- **Entrada:**
Dados pré-processados.
- **Processamento:**
Aplicação do modelo.
- **Saída:**
Score de risco ou classificação (bom/mau pagador).
- **Tecnologias sugeridas:**
Python, APIs REST (Flask).

Pós-processamento

- **Descrição:**
Interpreta e ajusta os resultados do modelo.
- **Entrada:**
Saída do modelo.
- **Processamento:**
 - Conversão de score em categorias
 - Ajustes de regras de negócio
- **Saída:**
Resultado final interpretável.
- **Tecnologias sugeridas:**
Airflow, Python.

Banco de Dados de Resultados

- **Descrição:**
Armazena o histórico de previsões realizadas.

- **Entrada:**
Resultados do modelo.
- **Processamento:**
Armazenamento estruturado.
- **Saída:**
Base histórica de análises.
- **Tecnologias sugeridas:**
PostgreSQL, Data Warehouse.

Dashboard e Análises

- **Descrição:**
Visualização dos resultados e métricas para tomada de decisão.
- **Entrada:**
Dados armazenados.
- **Processamento:**
Criação de gráficos e relatórios.
- **Saída:**
Painéis interativos.
- **Tecnologias sugeridas:**
Power BI, Tableau.

As tecnologias apresentadas são flexíveis e podem ser adaptadas conforme o volume de dados, infraestrutura disponível e maturidade tecnológica